



Mineração de Dados - Projeto Prático

Design de Experimentos

Prof^a. Vanessa Souza

Esse projeto é parte avaliativa da disciplina de Mineração de Dados e contemplará o planejamento da quinta e sexta fases CRISP-DM: Modelagem e Avaliação.

O trabalho será desenvolvido sob a abordagem de Aprendizado Baseado em Projetos (***Project-Based Learning – PBL***), na qual o processo de aprendizagem ocorre por meio da resolução de um problema real, demandando investigação, tomada de decisão e aplicação prática dos conceitos estudados. Nessa abordagem, os estudantes assumem um papel ativo na construção do conhecimento, sendo responsáveis por definir o problema, buscar dados relevantes e conduzir análises fundamentadas.

O **design de experimentos** (DoE) em Machine Learning é o processo sistemático de planejar, executar e analisar testes para avaliar como variações nos fatores de entrada — como hiperparâmetros, arquiteturas de modelos e subconjuntos de *features* — impactam as métricas de desempenho. Esse rigor metodológico é essencial para garantir a reprodutibilidade dos resultados, mitigar o viés de seleção e isolar estatisticamente o efeito de cada componente no pipeline de mineração de dados, transformando o ajuste de modelos de uma tarefa de tentativa e erro em um processo de engenharia robusto.

Portanto, nesta fase, cada grupo deverá **preparar seu design de experimentos**. O planejamento deve seguir a hierarquia experimental: para cada subconjunto de atributos (*feature set*), devem-se instanciar diferentes arquiteturas de modelos, submetendo cada combinação a um processo de otimização de hiperparâmetros.

O fluxo de execução do DoE será definido pela composição: Features → Modelo → Hiperparâmetros → Métricas de Avaliação

Dessa forma, para cada tripla (*feature*/modelo/hiperparâmetro), os grupos deverão extrair e documentar as métricas de desempenho pertinentes ao problema. Para a exploração eficiente do espaço de busca de parâmetros, é obrigatório o uso de técnicas de GridSearchCV ou RandomizedSearchCV da biblioteca *scikit-learn*, garantindo que a escolha da configuração final seja baseada em evidências estatísticas e não em ajustes ad-hoc.

As métricas devem ser documentadas tanto em relação ao treinamento, quanto em relação ao teste.

Atenção: o objetivo desta etapa é preparar o DoE, não executar!